

Inteligência Artificial:

Conceitos e aplicações de *Machine/Deep Learning* na medicina.

TIMOTHY GUSTAVO CAVAZZOTTO, PEF. MSc. PhD.
DEMED/UNICENTRO



Aspectos contextuais



1- Para qual finalidade você já usou a IA (na graduação)?

2- Tem medo da substituição?


3- Como vê o futuro?



O que é IA médica?


50 anos em 5 min

MYCIN → ImageNet → AlphaGo → Transformers → LLMs. *Por que levou tanto tempo?*



50 anos em 5 min

MYCIN → ImageNet → AlphaGo → Transformers → LLMs. *Por que levou tanto tempo?*



50 anos em 5 min

MYCIN → ImageNet → AlphaGo → Transformers → LLMs. *Por que levou tanto tempo?*

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com


Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Lukasz Kaiser*
Google Brain
lukaszkaizer@google.com


Illia Polosukhin* ‡
illia.polosukhin@gmail.com



[Artigo Transformers: 1706.03762](#)

[Transformers, the tech behind LLMs | Deep Learn... | 3Blue1Brown](#)

Aspectos contextuais



Diagnóstico?



Input
Chest x ray image

Diagnóstico?

Sintomas: tosse (seca ou com catarro amarelado/esverdeado), febre alta (acima de 38 °C), dor no peito, falta de ar, cansaço extremo e dores musculares



Como ensinar um computador a ler e diagnosticar?




Input
Chest x ray image



Como as máquinas aprendem?

Dados → treinamento → Validação → teste → generalização

Training




Inference




Como as máquinas aprendem?

JOGO: Encontre as Chaves




Guesses
0

Average
--



Guesses
17

Average
--




Guesses
42

Average
--

Como as máquinas aprendem?


5 4 3 2 1
Distance

JOGO: Encontre as Chaves



Guesses
0

Average
--




Guesses
6

Average
--

Média sem dica: 29-32
Média com dica: 4-6

Como as máquinas aprendem?

- *Ajustando palpites errados*: Aprender requer tentar diferentes ações para completar uma tarefa. Tentar a mesma ação errada não leva ao aprendizado.
- *Feedback*: Aprender é mais rápido quando o feedback não só diz quando você está errado, mas também *o quão* errado você está.



Guesses
42


Average
--



Distance

Como as máquinas aprendem?

Training




Treino: → tamanho do batch (32, 64, 128...) → número de epochs → learning rate inicial do Adam → epsilon da loss (1e-7), normalizar


Arquitetura: → número de camadas → tamanho das camadas → função de ativação (sigmoid, relu...)

Como as máquinas aprendem?


Inativado (0%)




Ativado (100%)





Ativado (50%)



Como as máquinas aprendem?



Como as máquinas aprendem?



Fase 0 — Dados



Preparação e divisão dos dados

Antes de qualquer treino — acontece uma única vez

- 1 Coleta das imagens**
Raio-X de tórax + laudos médicos como labels (14 doenças)
- 2 Verificação de data leakage**
Garantir que nenhum paciente aparece em mais de um conjunto
- 3 Divisão do dataset**
Treino (~70%) | Validação (~15%) | Teste (~15%)
- 4 Cálculo de μ e σ do treino**
Amostra aleatória das imagens de treino → média e desvio fixados
- 5 Cálculo das frequências de classe**
freq_pos e freq_neg por doença → pesos w_p e w_n

✓ μ , σ , w_p e w_n são calculados apenas com dados de treino e fixados para uso posterior no teste e validação.

Fase 1 — Pré-processamento



Pré-processamento das imagens

Aplicado a cada imagem antes de entrar na rede

- 1 Redimensionamento**
Imagem → 224x224 pixels (padrão DenseNet)
- 2 Normalização (treino)**
$$z = \frac{pixel - \mu_{batch}}{\sigma_{batch}}$$
usa estatísticas do batch
- 3 Normalização (val/teste)**
$$z = \frac{pixel - \mu_{treino}}{\sigma_{treino}}$$
usa valores fixos do treino
- 4 Agrupamento em batches**
Ex: 32 imagens por batch → processadas juntas na rede

i No treino, normalização por batch é aceitável. No teste e validação, usa-se μ e σ fixos — a rede não pode ter acesso a estatísticas dos dados de teste.

Fase 2 — Treino



Treinamento do modelo

Iterativo — repete para cada batch, em cada época

- 1 Forward pass**
Batch entra na DenseNet121 → features 7x7x1024 → GlobalAvgPool → Dense(14, sigmoid)
- 2 Cálculo da loss ponderada**
 $-(w_p \cdot y \cdot \log \hat{y} + w_n \cdot (1-y) \cdot \log(1-\hat{y}))$ por classe, somado
- 3 Backward pass (gradiente)**
Loss deriva em relação a cada um dos ~7M parâmetros
- 4 Atualização com Adam**
Ajusta taxa de aprendizado por parâmetro → pesos atualizados
- 5 Repete por N épocas**
Cada época = todos os batches do conjunto de treino

★ Os ~7M parâmetros da rede nunca são definidos manualmente — são aprendidos inteiramente pelo gradiente. Apenas os hiperparâmetros (batch size, épocas, learning rate) são escolhidos por você.

Fase 3 — Validação



Validação durante o treino

Avaliação ao final de cada época — sem atualizar pesos

- 1 Forward pass na validação**
Redes faz previsões no conjunto de validação
- 2 Cálculo das métricas**
AUC-ROC, F1-score, Precision, Recall, etc.
- 3 Monitoramento**
Verifica se o modelo está melhorando ou sobreajustando (overfitting)
- 4 Early Stopping (opcional)**
Para o treino se não houver melhora por X épocas

@ A validação guia o treinamento e evita overfitting. O conjunto de validação nunca é usado para atualizar os pesos.

Fase 4 — Teste



Avaliação final do modelo

Uma única vez, ao final do treino

- 1 Forward pass no teste**
Rede faz previsões no conjunto de teste (nunca visto antes)
- 2 Cálculo das métricas finais**
AUC-ROC, F1-score, Precision, Recall, etc.
- 3 Análise dos resultados**
Desempenho real do modelo em dados completamente novos
- 4 Relatório e interpretação**
Documentar resultados, curvas ROC, matriz de confusão, etc.

✓ O teste fornece uma estimativa honesta de como o modelo desempenha no mundo real.



Resumo do fluxo



Dados preparados com segurança



Imagens pré-processadas e normalizadas



Modelo treinado e pesos aprendidos




Validação monitora e orienta o treino



Teste avalia o desempenho final


Métricas de Performance - Treino

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)




$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

Tendência a acertar (em excesso)



Generalização

Dados de Treino



Paciente real



1 PONTO DE PARTIDA

Eles conhecem **sensibilidade e especificidade**.

		DOENÇA	
		Presente	Ausente
PREDITO PELO MODELO	Positivo	VP Verdadeiro Positivo	FP Falso Positivo
	Negativo	FN Falso Negativo	VN Verdadeiro Negativo



Sensibilidade
 $= VP / (VP + FN)$
(taxa de verdadeiros positivos)




Especificidade
 $= VN / (VN + FP)$
(taxa de verdadeiros negativos)



Essas métricas dependem do ponto de corte escolhido.

2 CURVA ROC


Construir a curva ROC a partir daí — é só mover o ponto de corte.



Cada ponto da curva = um ponto de corte diferente.
AUC resume a capacidade do modelo de discriminar.

3 AUC: O QUE SIGNIFICA?

AUC: “se eu jogar um caso doente e um sadio para o modelo, qual a chance de ele ordenar certo?”




$AUC = P(\text{score do doente} > \text{score do sadio})$

- 1,0** Perfeito
- 0,5** Como jogar moeda
- 0,0** Totalmente invertido

4 CALIBRAÇÃO

O modelo diz 80% de risco — isso significa que 80 em 100 pacientes assim desenvolvem a doença? Quase nunca.



Calibrado = previsões coerentes com a realidade.
Descalibrado = confia no número errado.



5 IMPACTO CLÍNICO: O NÚMERO NÃO É TUDO

Um modelo com **AUC 0,92** pode ser inútil se **mal calibrado** ou testado numa **população diferente** da sua.



Alta AUC não garante bons resultados na prática



Calibração importa para decisões e confiança



Valide sempre na sua população e cenário de uso real



Performance só faz sentido se gerar benefício para o paciente.

VIÉS NA IA MÉDICA: QUANDO DADOS NÃO REPRESENTAM TODOS, DECISÕES NÃO SERVEM PARA TODOS.



Termo	Definição	Equivalente em Epidemiologia Clínica
Matriz de Confusão (Confusion Matrix)	Tabela que compara os rótulos verdadeiros (ground truth) com as previsões do modelo.	Tabela de contingência (2×2)
Época (Epoch)	Uma passagem completa por todo o conjunto de treinamento.	Iteração
Característica (Feature)	Informação de entrada utilizada pelo modelo (ex.: pixels, variáveis clínicas).	Preditor, covariável, variável independente
Ground Truth	Rótulo ou diagnóstico considerado verdadeiro, definido por especialistas ou padrão de referência.	Padrão de referência (Gold Standard)
Hiperparâmetro (Hyperparameter)	Configuração definida antes do treinamento e que não é aprendida pelos dados (ex.: taxa de aprendizado, número de camadas).	Especificação do modelo
Kernel	Filtro utilizado nas convoluções para detectar padrões em imagens.	<i>Sem equivalente direto</i>
Rótulo (Label)	Classe ou resultado associado a uma observação.	Desfecho, variável resposta
Saída do Modelo (Prediction)	Probabilidade ou classificação produzida pelo modelo para cada classe possível.	Predição


Termo	Definição	Equivalente em Epidemiologia Clínica
Parâmetro (Parameter)	Valor aprendido automaticamente durante o treinamento.	Coeficiente do modelo
Precisão (Precision)	Proporção de casos classificados como positivos que realmente são positivos.	Valor Preditivo Positivo (VPP)
Recall	Proporção de casos positivos corretamente identificados pelo modelo.	Sensibilidade
Classificador Sigmoid	Produz probabilidades independentes para cada classe.	Regressão logística
Classificador Softmax	Produz probabilidades mutuamente exclusivas que somam 100%.	Regressão logística multinomial
Treinamento (Training/Learning)	Processo de ajuste iterativo dos parâmetros para melhorar o desempenho do modelo.	Ajuste do modelo
Exemplo de Treinamento	Observação com entrada e rótulo conhecido utilizada para treinar o modelo.	Caso, observação, ponto de dado
Transfer Learning	Uso de pesos previamente aprendidos em outro problema para acelerar o treinamento.	Sem equivalente direto
Peso (Weight)	Intensidade da conexão entre neurônios da rede neural.	Coeficiente do modelo

RAG — Retrieval-Augmented Generation


geração aumentada por recuperação

Por que um LLM sem RAG é diferente — e por que isso importa na clínica

LLM SEM RAG



LLM COM RAG



IMPLICAÇÃO CLÍNICA — O QUE PERGUNTAR ANTES DE USAR UM LLM MÉDICO



Qual é a data de corte?

Um modelo treinado até 2022 não conhece diretrizes publicadas em 2023. Sem RAG, é como consultar um colega que não lê a literatura há dois anos.



Que base ele consulta?

RAG é tão bom quanto a base de dados usada. PubMed atualizado é diferente de um corpus proprietário desconhecido. Pergunte ao fabricante.



Há citação verificável?

Um LLM com RAG deve apontar a fonte. Se a resposta não cita nada, trate como opinião — não como evidência. Verifique antes de agir.

Diagnóstico

Deep learning in medical image analysis: introduction to underlying principles and reviewer guide using diagnostic case studies in paediatrics


Constance Dubois,¹ David Eigen,² Emmanuel Delmas,³ Margot Einfalt,⁴ Clara Lemaçon,⁵ Laureline Berteloot,⁶ Patrick M Bossuyt,⁷ David Drummond,⁸ Pauline Scherdel,¹ François Simon,⁹ Héloïse Torchin,^{1,10} Yasaman Vali,⁷ Isabelle Bloch,¹¹ Jérémie F Cohen^{1,12}

thebmj | *BMJ* 2024;387:e076703 | doi: 10.1136/bmj-2023-076703



Diagnóstico com IA

89	147	122	53	52	58	56	74	73	92
88	150	112	55	49	57	57	80	70	98
90	146	103	79	61	69	69	68	67	107
88	137	102	95	81	75	75	67	82	124
86	130	115	103	88	91	91	80	103	107
81	135	121	110	80	90	113	123	139	124
74	140	131	109	96	70	81	145	154	143
74	139	136	114	114	98	117	135	130	130
75	127	130	123	120	137	138	130	133	145
73	118	121	132	142	141	143	148	156	162



Diagnóstico com IA






Fig 2 | Examples of convolution filtering for analysis of a chest x ray image: (A) original image; (B) gaussian blur; (C) edge detecting kernel; and (D) Sobel kernel detecting horizontal edges

Diagnóstico com IA

Example of a class activation map for medical image analysis, which highlights the areas of the chest x ray image that are most important for making a particular pathology classification (example shows pneumonia).



Input
Chest x ray image



Output
Pneumonia positive (85%)



Oftalmologia

IDx-DR FDA 2018

Triagem autônoma de retinopatia diabética. Primeiro sistema aprovado sem supervisão médica obrigatória.

DeepMind / Moorfields

50+ doenças oculares em OCT. Desempenho equivalente a especialistas.



Radiologia

Nódulo pulmonar (TC)

Supera radiologista júnior; inferior ao sênior assistido por IA. Modelo: Sybil (MIT).

CheXNet / CheXpert

14 achados em RX de tórax. Base para múltiplos modelos clínicos derivados.



Cardiologia

ECG — Apple Watch FDA 2018

Fibrilação atrial em população geral. 98% sensibilidade em estudos validados.

ECG → fração de ejeção

Modelo da Mayo Clinic prediz disfunção sistólica silenciosa com AUC 0,93.



Patologia digital

Paige Prostate FDA 2021

Detecção de câncer de próstata em lâminas digitalizadas. Reduz casos perdidos em 70%.

Câncer de mama (Google)

Redução de 9,4% em falsos negativos vs. patologista solo (Nature, 2020).



Dermatologia

Melanoma (Stanford)

CNN iguala dermatologistas em classificação de lesões. Testada em 21 especialistas (Nature, 2017).

DermAssist (Google)

288 condições a partir de foto. Ainda sem aprovação regulatória ampla.



Neurologia / LLMs

Alzheimer em RNM pesquisa

Predição de conversão MCI → demência com 6 anos de antecedência.


Med-PaLM 2 LLM

Passa no USMLE. Alucina referências com confiança — copiloto, não piloto.

Prognóstico

Predição de deterioração clínica: NEWS vs. modelo de IA

O mesmo objetivo, duas abordagens — e consequências clínicas diferentes





Deterioração clínica / sepse

Epic Sepsis Model implantado
AUC 0,76. Usado em centenas de
hospitais nos EUA. Validação externa
mostrou alta taxa de alarme falso.

COMPOSER (Stanford) validado

Prediz sepse 4–6h antes. XGBoost
com variáveis de tendência. Reduz
mortalidade em RCT piloto.



Readmissão hospitalar

Modelo 30 dias (Epic/CMS)
implantado
Prediz readmissão em 30 dias pós-
alta. Usado para triagem de
acompanhamento intensificado.

LACE+ Score + ML
Escore clínico aumentado com
variáveis de contexto social. Melhora
AUC de 0,68 → 0,79.



Oncologia — progressão e sobrevida

Predição de sobrevida (NSCLC)
pesquisa
CNN em TC de tórax prediz sobrevida
em 2 anos com AUC 0,86 (Nature
Medicine, 2019).

Resposta à imunoterapia
Modelo multimodal (imagem +
genômica + clínico) prediz resposta
ao PD-1 antes do 2º ciclo.



Neurologia / demência

MCI → demência (Alzheimer)
pesquisa
CNN em RNM prediz conversão com
6 anos de antecedência. AUC 0,84 em
validação prospectiva.

AVC — prognóstico funcional
Prediz desfecho funcional (mRS) em
90 dias com base em imagem e
dados clínicos de admissão.



Insuficiência cardíaca

Predição de hospitalização
implantado
Modelo integrado ao
telemonitoramento domiciliar (peso,
PA, BNP). Ativa contato proativo da
equipe.

Mortalidade em 1 ano (Mayo)
validado
ECG + dados clínicos. AUC 0,88.
Identifica pacientes para
encaminhamento a transplante ou
DACM.



UTI — mortalidade e tempo de ventilação


DeepSOFA validado
LSTM usando séries temporais de
variáveis SOFA. Supera APACHE II na
predição de mortalidade em UTI.

**Desmame de VM — predição de
falha**
Modelo com padrão respiratório e
variabilidade de FC prediz falha no
desmame com 8h de antecedência.


Tratamento

Watson *Oncology*

FLUXO: O QUE FOI PROMETIDO



O QUE FALHOU — E POR QUÊ



MedGemma — Google DeepMind

open source

Coleção de modelos fundacionais para texto e imagem médica, lançada em maio de 2025 no Google I/O · Construída sobre a arquitetura Gemma 3

MedGemma 4B · multimodal

Texto + imagem

4 bilhões de parâmetros. Encoder visual MedSigLIP integrado. Leve o suficiente para rodar localmente.

- Raio-X, TC, RNM, dermatologia, patologia, fundo de olho
- Classificação, VQA médico, geração de laudos
- Treinável localmente com fine-tuning supervisionado

MedGemma 27B · texto

Raciocínio clínico profundo

27 bilhões de parâmetros, apenas texto. Otimizado para compreensão e inferência clínica complexa.

- Extração de informação de prontuários (EHR)
- Raciocínio clínico e resposta a perguntas (USMLE)
- Diretrizes clínicas, diálogos médico-paciente

MedGemma 27B · multimodal

Texto + imagem · escala grande

Versão mais capaz. Integra texto clínico e imagem médica. Contexto longo (128k tokens).

- Laudo radiológico com histórico clínico integrado
- Multimodalidade: imagem + texto interleaved
- Base para frameworks agênticos em saúde

PERFORMANCE — BENCHMARKS PUBLICADOS (MEDGEMMA 27B · JUL 2025)

MedQA (USMLE)

89,8%

Acima do nível de aprovação humana (~60%)

MMLU Medical

92,3%

Benchmark de conhecimento médico amplo

Raio-X tórax (CXR) ·
MedGemma 4B

80,4%

vs. GPT-4o: 69,6% ·
classificação de doenças

EHR retrieval (erro)

–50%

Com fine-tuning vs. modelo base · extração de prontuários



Oncologia de precisão

Watson Oncology

descontinuado

Recomendações inseguras em pacientes reais. Treinado com casos hipotéticos, não prontuários.

MSK OncoKB + IA em uso

Base de variantes tumorais + suporte à escolha de terapia-alvo. Curado por oncologistas especialistas.



Radioterapia

Contorno automático (auto-segmentation) FDA

IA delimita volumes tumorais e órgãos de risco em minutos. Reduz tempo de planejamento de horas para ~20 min.

Adaptive radiotherapy validado

Replanejamento diário automático baseado em mudanças anatômicas. Reduz dose em órgãos saudáveis.



Ajuste de dose e antibioticoterapia

Vancomicina — dosagem

Bayesiana em uso

Modelo PK/PD ajusta dose em tempo real com base em níveis séricos e função renal. Reduz nefrotoxicidade.

Stewardship antimicrobiano

validado

Alerta para escalada/desescalada de antibiótico baseado em cultura + contexto clínico. AUC 0,82.



Suporte à decisão em UTI

Vasopressores — desmame guiado pesquisa

Reinforcement learning sugere protocolo de desmame de norepinefrina. RCT em andamento (2024).

Nutrição enteral personalizada

validado

Ajuste calórico/proteico diário com base em gasto energético medido por calorimetria indireta + ML.



Drug discovery

AlphaFold + design molecular

pesquisa

Predição de estrutura proteica viabiliza design racional de moléculas. Revolucionou biologia estrutural.

INX-315 — CDK2 inhibitor

Phase IIa +

Primeiro candidato gerado por IA com resultado positivo em ensaio clínico Phase IIa (Nat Med, 2025).



Cardiologia intervencionista

Guia de ablação por FA validado

IA identifica regiões-alvo para ablação em tempo real durante cateterismo. Reduz recorrência em 18%.

TAVI — seleção e planejamento

em uso


IA mede anel aórtico em TC e seleciona tamanho de valva automaticamente. Erro < 1mm vs. especialista.

Futuro

O MÉDICO DO FUTURO

A tecnologia muda. O cuidado continua sendo humano.

IA



A IA começa
sugerindo possibilidades e apoiando decisões.



O médico decide
com julgamento clínico, experiência e valores do paciente.



O cuidado acontece
com empatia, presença e responsabilidade.

MÉDICO



A IA COMEÇA E TERMINA COM SERES HUMANOS.

Tecnologia sem humanidade é algoritmo. Humanidade sem tecnologia é limitada.

Juntos, são transformação.



**O MELHOR MÉDICO DO FUTURO
PROVAVELMENTE NÃO SERÁ SUBSTITUÍDO PELA IA.
SERÁ ALGUÉM QUE SABE TRABALHAR COM ELA.**



PERGUNTA FINAL:

O que você quer que a IA faça por você quando você for o paciente?



Leituras adicionais

- [AI in health and medicine | Nature Medicine](#)
- [History of artificial intelligence in medicine - Gastrointestinal Endoscopy](#)
- <https://physicianaihandbook.com/>
- [Pranav Rajpurkar, PhD - Google Scholar](#) (pesquisador TOP1% em AI in Medicine)
- [The generative era of medical AI - ScienceDirect](#)

Obrigado

Linhas de pesquisa:

- Uso de Modelos (ML e DL) para predições em saúde;
- Exercício, saúde e doença

Empresas:


- Metthods Analytics
- Studio Mets – noua.ia

Disciplinas:

- Bioestatística
- IA na Medicina

Sites:

- sites.google.com/view/professortimothycavazzotto
- www.calculadoralactase.com.br
- noua.ia.br
- projeto80+



@STUDIO.METS



METTHODS CONSULTORIA

Email:

tcavazzotto@unicentro.br